

Professor: Thiago Goveia	Conteúdo: Trabalho prático 01	Apresentação: 27/04/2026	Valor: 12pts
------------------------------------	---	------------------------------------	------------------------

Objetivos de Aprendizagem

Ao final deste trabalho, o grupo deverá ser capaz de:

1. Identificar e documentar problemas de qualidade em bases de dados reais.
2. Aplicar técnicas de pré-processamento: integração, limpeza, transformação e criação de atributos.
3. Produzir visualizações adequadas ao tipo de dado e à pergunta analítica.
4. Relacionar cada decisão técnica com o referencial teórico do Tan et al. (2006).

Descrição do trabalho

Na primeira avaliação, vocês responderam questões teóricas e práticas (usando Pandas) sobre os Capítulos 1 e 2 do livro de Tan et al. (2006). Agora chegou a hora de fazer o que o capítulo ensina: pré-processar dados reais, cruzar bases, tratar inconsistências e extrair insights por meio de visualizações. As três bases de dados disponibilizadas registram, respectivamente:

Base	Arquivo	Conteúdo
Prova	TP01_-_Bases_de_dados _-_prova.csv	Gabarito por aluno: acerto (1), erro (0) ou questão pulada (vazio) em cada uma das 15 questões, além de nota, faltas e frequência
Questões	TP01_-_Bases_de_dados _-_questoes.csv	Metadados de cada questão: assunto, simulado de origem e se era questão de código
Formulário	TP01_-_Bases_de_dados _-_formulario.csv	Respostas da sondagem pós-prova: percepção de dificuldade, horas de estudo, uso de simulados, nível de compreensão por tema, entre outros

Usando as bases **devidamente tratadas**, produza um conjunto de visualizações que respondam às perguntas analíticas abaixo. Cada visualização deve ser acompanhada de: (a) o tipo de gráfico utilizado e a justificativa da escolha; (b) os principais insights encontrados.

Perguntas Analíticas

- **P1 — Distribuição das notas:** Mostre a distribuição das notas reais da turma. Use pelo menos dois tipos de gráfico diferentes (ex.: histograma e box plot) e compare as turmas entre si.
- **P2 — Desempenho por questão:** Mostre a taxa de acerto de cada questão, ordenada da menor para a maior. Identifique as questões mais e menos difíceis. Plo
- **P3 — Desempenho por assunto:** Agregue a taxa de acerto pelo assunto de cada questão e apresente graficamente. Esse resultado é coerente com o que os alunos reportaram sobre facilidade de compreensão no Formulário?
- **P4 — Relação entre estudo e desempenho:** Investigue se existe relação entre o número de horas de estudo (ou o número de simulados realizados) e a nota obtida. Use um gráfico de dispersão e calcule a correlação.
- **P5 — Percepção vs. realidade:** Compare a nota que o aluno esperava tirar (Qual nota você acha que tirou?) com a nota real. Produza um gráfico de dispersão e interprete os desvios.
- **P6 — Perfil dos alunos com melhor desempenho:** Escolha um critério para definir "melhor desempenho" (ex.: nota acima da mediana). Use pelo menos um gráfico de barras ou histograma para comparar alguma característica desse grupo com o restante da turma.
- **P7 — Definida pelo grupo:** O gráfico deve ser do Radar ou de Coordenadas Paralelas
- **P8 — Definida pelo grupo:** O gráfico deve ser um Heatmap de uma correlação ou de desempenho de aluno $\times$ questão
- **P9 — Definida pelo grupo**
- **P10 — Definida pelo grupo**

Para responder todas as perguntas, você deverá tratar a base de dados, cumprindo os requisitos descritos a seguir:

Como fazer:

Parte 1 — Diagnóstico das Bases de Dados

Antes de qualquer tratamento, o grupo deve documentar o estado inicial das três bases.

1.1 Descrição dos Atributos

Para cada base, construa uma tabela descrevendo todos os atributos com as seguintes colunas:

- Nome do atributo
- Tipo de atributo segundo a classificação do Tan (nominal, ordinal, intervalo, razão)
- Discreto ou contínuo
- Exemplo de valor

1.2 Problemas de Qualidade Identificados

Investigue e liste todos os problemas encontrados nas bases. Para cada problema, informe:

- Base e atributo onde ocorre
- Tipo de problema (valor ausente, inconsistência, dado duplicado, ruído, tipo inadequado etc.)

- Frequência ou extensão do problema (quantos registros afetados)

Problemas sugeridos para investigação (mas não se limite a eles):

- Questões puladas na base Prova: representam valores ausentes ou uma categoria legítima de resposta?
- A coluna Nota Questões está em qual tipo numérico? Há inconsistência de formatação?
- O campo Término (horário de entrega) está em formato adequado para análise?
- Há alunos na base Prova que não responderam ao Formulário? Como tratar isso?
- O campo Quantas horas você estudou no Formulário tem qual tipo de dado? Há padronização?
- As colunas de percepção de compreensão por tema têm escala ordinal consistente?

Parte 2 — Pré-processamento

2.1 Integração das Bases

Tarefa: Produza uma base integrada unindo as três fontes de dados.

- Una a base Prova com a base Formulário a partir do identificador do aluno (Código/ID).
Documente quantos registros encontraram correspondência e como tratar os que não encontraram.
- Incorpore os metadados das Questões (assunto, simulado de origem, se é questão de código) como novas colunas.

2.2 Limpeza de Dados

Para cada problema identificado na Parte 1, aplique uma estratégia de tratamento justificada. As estratégias possíveis incluem:

- **Eliminar** o registro ou atributo (justifique por que a perda é aceitável)
- **Imputar** o valor ausente (média, mediana, moda, valor mais frequente na turma, ou valor baseado no contexto)
- **Padronizar** o formato (ex.: converter horário de término para minutos, converter nota de vírgula para ponto decimal, textos em números)
- **Corrigir** inconsistências detectadas

2.3 Criação de Atributos

Crie pelo menos **4 novos atributos** a partir dos dados existentes. Sugestões (escolha no máximo 2 e crie os demais):

Atributo sugerido	Descrição
tempo_prova_min	Diferença entre o horário de término e o horário de início da prova, em minutos
taxa_acerto	Proporção de acertos entre as questões efetivamente respondidas

media_compreensao	Média da escala de compreensão por tema respondida no Formulário (converter para numérico: Não entendi=1, Entendi apenas a teoria=2, Entendi com facilidade=3)
simulados_realizados	Contagem de quantos dos três simulados o aluno realizou (completo ou parcialmente)
acertou_codigo	Proporção de acertos nas questões identificadas como "questão de código"
erro_esperado	Diferença entre a nota que o aluno esperava tirar (Formulário) e a nota real

2.4 Transformações e Normalização

Aplique as seguintes transformações nos atributos:

- **Discretização** de ao menos 1 atributo contínuo. Documente o método (igual largura, igual frequência ou baseado em entropia) e justifique.
- **Normalização/padronização** de todos os atributos numéricos utilizados.
- **Binarização** de ao menos 1 atributo numérico nominais (Todos os atributos nominais utilizados devem ser binarizados).

2.5 Agregação

Produza pelo menos 2 visões agregadas dos dados. Exemplos (escolha no máximo 1):

- Taxa média de acerto por questão (agrupando por Questão)
- Taxa média de acerto por assunto (agrupando por Assunto)
- Desempenho médio por turma
- Número médio de horas de estudo por faixa de nota

Parte 3 — Reflexão Crítica

Apresente:

1. Qual foi a decisão de pré-processamento mais difícil de tomar? Por quê?
2. Quais insights dos dados surpreendem vocês? Algum resultado vai contra a intuição inicial?
3. Que dados adicionais vocês gostariam de ter para aprofundar a análise?

Entregáveis

Arquivo	Descrição
relatorio_TP02_GrupoXX.pdf	Relatório/Slide contendo todas as partes, com tabelas, gráficos e textos interpretativos
TP02_GrupoXX.ipynb	Código-fonte completo, comentado, reproduzível a partir dos arquivos CSV originais
base_integrada_GrupoXX.csv	Base de dados final, tratada e integrada

Critérios de Avaliação

- Diagnóstico completo e correto dos problemas de qualidade
- Aplicação correta e justificada das técnicas de pré-processamento
- Qualidade das visualizações e profundidade da interpretação
- Reflexão crítica e coesão da apresentação

Dicas Técnicas

- Carregue os CSVs com `sep='|'` e `encoding='latin1'` (ou `'utf-8-sig'`).
- Ao trabalhar com a coluna `Nota Questões`, substitua a vírgula por ponto antes de converter para float: `df['Nota Questões'].str.replace(',', '.').astype(float)`.
- Questões puladas aparecem como NaN nas colunas Q1–Q15. Defina explicitamente como seu grupo vai interpretá-las antes de calcular taxas de acerto.
- Para o gráfico de parallel coordinates em Python, use `pandas.plotting.parallel_coordinates` ou `plotly.express.parallel_coordinates`.
- Para o heatmap de desempenho aluno × questão, `seaborn.heatmap` é uma boa opção.