



**CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA DE MINAS GERAIS**  
ENGENHARIA DE COMPUTAÇÃO - CAMPUS VII, TIMÓTEO-MG  
**Trabalho prático 02 - Ciência de Dados I**

|                                    |                                                             |                                    |                        |
|------------------------------------|-------------------------------------------------------------|------------------------------------|------------------------|
| <b>Professor:</b><br>Thiago Goveia | <b>Conteúdo:</b><br>Trabalho prático 02- Mineração de Dados | <b>Apresentação:</b><br>01/07/2026 | <b>Valor:</b><br>40pts |
|------------------------------------|-------------------------------------------------------------|------------------------------------|------------------------|

## 1. Contexto e Motivação

O Sistema de Seleção Unificada (SISU) seleciona candidatos para vagas em instituições públicas de ensino superior com base nas notas do ENEM. Este trabalho propõe a construção de dois classificadores distintos sobre os dados da Lista de Espera 2/2023 do SISU, cada um respondendo a uma pergunta de negócio diferente — uma do ponto de vista do candidato e outra do ponto de vista da instituição.

[Clique aqui para baixar a base de dados](#)

## 2. Os Dois Problemas de Classificação

### Problema A — Perspectiva do Candidato

**Pergunta:** "Dado que me inscrevi na lista de espera, serei convocado?"

**Variável-alvo:** APROVADO (S / N) — Classificação binária

**Features permitidas:** apenas dados disponíveis antes do resultado:

- Notas brutas do ENEM: NOTA\_L, NOTA\_CH, NOTA\_CN, NOTA\_M, NOTA\_R
- Notas com peso: NOTA\_L\_COM\_PESO, NOTA\_CH\_COM\_PESO, NOTA\_CN\_COM\_PESO, NOTA\_M\_COM\_PESO, NOTA\_R\_COM\_PESO (pesos são públicos no edital)
- Dados do curso: CODIGO\_IES, CODIGO\_CURSO, GRAU, TURNO, MOD\_CONCORRENCIA, TP\_COTA, OPCA
- Dados pessoais: SEXO, DT\_NASCIMENTO, UF\_CANDIDATO

**Features proibidas (leakage):** NOTA\_CORTE, CLASSIFICACAO, MATRICULA, NOTA\_CANDIDATO (se for calculada com algum fator pós-processo), CPF, etc.

**Princípio fundamental:** o modelo só pode usar informações que o candidato teria disponíveis no momento em que faz a pergunta, antes de qualquer resultado ser divulgado.

### Problema B — Perspectiva da Instituição

**Pergunta:** "Dado que um candidato foi convocado, ele efetivará a matrícula?"

**Variável-alvo:** MATRICULA (Sim / Não) — Classificação binária

**Features permitidas** — todas disponíveis no momento da convocação:

- Todas as features do Problema A
- NOTA\_CORTE (já definida quando a convocação ocorre)
- CLASSIFICACAO (posição do candidato na lista)
- Feature sugerida: MESMA\_UF (UF\_CANDIDATO == UF\_CAMPUS)

### 3. Modelos a Implementar

Cada grupo deve implementar os 6 modelos a seguir para resolver os dois problemas. A divisão em duplas determina quais modelos cada dupla implementa:

| Modelo            | Hiperparâmetros Mínimos a Avaliar              | Dupla   |
|-------------------|------------------------------------------------|---------|
| Árvore de Decisão | max_depth, criterion (gini/entropy)            | Dupla 1 |
| KNN               | n_neighbors, metric (euclidean/manhattan...)   | Dupla 2 |
| Random Forest     | n_estimators, max_depth, max_features          | Dupla 1 |
| Naive Bayes       | Tipo: GaussianNB ou MultinomialNB (justificar) | Dupla 2 |
| Gradient Boosting | n_estimators, learning_rate, max_depth         | Dupla 1 |
| SVM               | kernel (linear/rbf/poly), C                    | Dupla 2 |

### 4. Organização do Grupo

O grupo de 4 integrantes deve se dividir em duas duplas fixas:

| Dupla   | Modelos                                             | Responsabilidade compartilhada (sugestão)                           |
|---------|-----------------------------------------------------|---------------------------------------------------------------------|
| Dupla 1 | Árvore de Decisão, Random Forest, Gradient Boosting | EDA(Exploratory Data Analysis), pré-processamento, pipeline base    |
| Dupla 2 | KNN, Naive Bayes, SVM                               | Pré-processamento, Feature engineering, análise comparativa, slides |

Cada dupla implementa seus 3 modelos para os dois problemas (A e B). A análise comparativa final — reunindo todos os 6 modelos — é responsabilidade conjunta do grupo.

### 5. Etapas do Trabalho

#### Etapa 1 — Análise Exploratória (EDA)

1. Inspecionar o dataset: shape, tipos de dados, valores nulos, duplicatas;
2. Analisar distribuição da variável-alvo em cada problema (balanceamento);
3. Gerar ao menos 5 visualizações relevantes (distribuição de notas, mapa de correlação, distribuição geográfica, etc.);
4. Identificar e documentar possíveis outliers.

#### Etapa 2 — Pré-processamento

5. Remover features de identificação e leakage (conforme Seção 2);
6. Tratar valores ausentes com estratégia justificada;
7. Criar features (Obrigatório: MESMA\_UF para o Problema B);

8. Codificar variáveis categóricas com estratégia adequada e justificada (Ordinal ou One-Hot);
9. Normalizar variáveis numéricas quando necessário (obrigatório para KNN e SVM);
10. Separar treino/teste com split estratificado, com `random_state=42`

**Atenção no item 10:** O grupo deve decidir entre utilizar Validação Cruzada (Treino + Teste) ou Separação simples (Holdout, com conjunto de Validação). Embora estejamos adotando uma metodologia conjunta nas aulas, a qual é mais robusta (CV + Validação), no TP vocês devem optar por uma das 2 estratégias mais simples, por uma questão de tempo de computacional, visto que o dataset é muito grande. Além disso, vocês podem optar pela amostragem.

### Etapa 3 — Treinamento e Tuning

11. Cada dupla implementa seus 3 modelos para o Problema A;
12. Cada dupla implementa seus 3 modelos para o Problema B;
13. Realizar busca de hiperparâmetros. **Se o grupo optar por usar Holdout sem CV, deve pesquisar como fazer a busca por hiperparâmetros neste caso, pois os métodos da sklearn pressupõem o uso de CV.**
14. Registrar os melhores hiperparâmetros encontrados e o tempo de treinamento de cada modelo.

### Etapa 4 — Avaliação e Comparação

15. Calcular a métrica [AUC-ROC](#) e outra métrica pertinente (Acurácia, Precision, etc);
16. Gerar Matriz de Confusão para cada modelo em cada problema;
17. Gerar curva ROC comparativa (todos os 6 modelos em um único gráfico, por problema);
18. Montar tabela de ranking com métricas + tempo de treinamento para cada problema;
19. Identificar Feature Importance nos modelos que suportam (Árvore, Random Forest e GB);
20. Comparar e discutir: como o mesmo modelo se comporta diferentemente nos dois problemas?

### Etapa 5 — Apresentação

21. Preparar slides conforme o script fornecido (Seção 11);
22. Apresentação oral de 10 a 12 minutos (Apenas 1 ou 2 integrantes);

**Atenção:** A apresentação poderá ser interrompida, caso ultrapasse o limite de tempo

## 6. Entregáveis

Arquivo **TP02\_GrupoXX.zip** (apenas .zip) contendo:

| Item                           | Descrição                                                      |
|--------------------------------|----------------------------------------------------------------|
| <b>nb_TP02_GrupoXX.ipynb</b>   | Pipeline completo: EDA, pré-processamento, modelos, comparação |
| <b>slides_TP02_GrupoXX.pdf</b> | Apresentação conforme script fornecido (apenas PDF)            |

## 8. Considerações Técnicas

- Use `random_state=42` em todos os experimentos para garantir reprodutibilidade;
- Documente cada decisão no notebook com células Markdown explicativas;
- Para KNN e SVM, normalize os dados antes do treinamento;
- Para o Problema B, trate o desbalanceamento de classes antes de treinar;

## 9. Cronograma

|              |                                                             |
|--------------|-------------------------------------------------------------|
| <b>08/06</b> | Entrega das provas e esclarecimento de dúvidas sobre o TP02 |
| <b>10/06</b> | Acompanhamento                                              |
| <b>15/06</b> | Acompanhamento                                              |
| <b>17/06</b> | Acompanhamento                                              |
| <b>22/06</b> | Acompanhamento                                              |
| <b>24/06</b> | Regressão Linear e Interpretabilidade                       |
| <b>29/06</b> | Regressão Linear e Interpretabilidade (Atividade)           |
| <b>01/07</b> | Apresentação do TP02                                        |

**Atenção:** A nota é individual. Será analisada a efetiva participação no trabalho ao longo do acompanhamento. Todos os integrantes devem estar aptos a explicar qualquer decisão do trabalho da dupla.

## 10. Pontuação

- **5pts:** Apresentação (Qualidade, tempo, decisões, resultados, etc)
- **30pts:** Modelos
- **5pts:** Decisões de projeto

## 11. Script de apresentação

1. EDA e pré-processamento - Apresentar uma tabela (ou tabelas) com informações sobre os problemas A e B:
  - Seleção de dados: Features utilizadas ( e justificativa)
  - Decisões de pré-processamento mais relevantes
2. Processamento:
  - Decisões de mineração de dados mais relevantes:
    - Busca e seleção de hiperparâmetros
    - Estratégia de split, quantidade de dados e porcentagens pertinentes
    - Métricas de desempenho
3. Resultados (Pós-processamento)
  - Para cada modelo, apresentar (tabela):
    - Hiperparâmetros
    - Tempo de execução
    - Desempenho com a métrica escolhida
  - Apresentar as curvas AUC-ROC (2 gráficos apenas, 1 para cada problema)
4. Conclusão e outros pontos relevantes