

Ciência de
Dados I

TP02

Mineração de Dados

Grupo 06

Previsão de Efetivação de Matrícula no SISU

Lista de Espera 2/2023

Jonas Camargo

Lucas Aquino

A base de dados

- 148.773 registros × 56 colunas.
- Cada linha = candidato × opção de curso (a pessoa aparece várias vezes).
- Notas do ENEM, curso/campus, cota, nota de corte, classificação e status.
- Leitura: separador “|”, codificação Latin-1 e vírgula decimal.

148.773

registros na base bruta

56

colunas originais

Definindo quem é o quê

4 / 12


44.504

convocados resolvidos

38,1%

efetivam a matrícula

- Funil: 148.773 → exclui não convocados e pendentes.
- EFETIVOU = 1 se matrícula concluída; 0 caso contrário.
- Após filtragem -> 44.504 candidatos válidos
- Base moderadamente desbalanceada pós filtragem (38% positivos).



Distribuição do alvo EFETIVOU

✖ Removidas (principais)

- Identificadores: CPF, nome, inscrição ENEM
 - Não generaliza o aprendizado
 - Dados sensíveis
- Constantes: ANO, EDIÇÃO, APROVADO
 - Sem variância
- 5 notas por área (redundantes, colinearidade $\approx 0,75$), Mantivemos NOTA_CANDIDATO
- Alta cardinalidade: curso, IES, município
 - One-Hot explodiria
- PERCENTUAL_BONUS (95% vazio)

✔ Criadas

- MESMA_UF — candidato no mesmo estado do campus
- IDADE — derivada do ano de nascimento
- MARGEM — nota do candidato menos a nota de corte (folga sobre o corte)

Engenharia de atributos

Features totais iniciais

DIRETAS	CRIADAS
GRAU	IDADE <- DT_NASCIMENTO
TURNO	MESMA_UF <- UF_CANDIDATO + UF_CAMPUS
TP_COTA	MARGEM <- NOTA_CANDIDATO - NOTA_CORTE
TIPO_MOD_CONCORRENCIA	
SEXO	
OPCAO	
NOTA_CANDIDATO	
NOTA_CORTE	
QT_VAGAS_CONCORRENCIA	
CLASSIFICACAO	


A nota

5 / 12

~16 pts

diferença de mediana entre as classes (escala 0–1000)

- As distribuições de notas quase se sobrepõem.
- Todos já passaram pelo filtro da convocação.
- a decisão de efetivar não está necessariamente na nota.



Notas por classe (0 = não efetivou · 1 = efetivou)

O que decide é o contexto

Com as três novas features, percebemos que

43,7% × 18,8%

efetivação na mesma UF vs de fora

42,6% × 28,4%

1ª opção vs 2ª opção

47% → 3%

top 10 vs acima de 100 na lista de espera

- *Quem é chamado por último ou longe de casa tende a desistir.*
- *Quem está no início da fila, tem tempo de se acomodar*

Quem é o candidato

54%

têm 18–21 anos (mediana 19, recém-saídos do EM)

42,2% × 35,7%

efetivação: homens vs mulheres

57%

concorrem na ampla concorrência (sem cota)

- Público majoritariamente jovem; cauda de estudantes mais velhos (até 75).
- O jovem recém saído do ensino médio tende a efetivar mais.
- Cota vazia = ampla concorrência → virou categoria própria em vez de NaN (evitar o vazamento).

O que de fato foi para o treinamento

9 / 12

13 → 32

features → colunas (após One-Hot
Encoding)

20.330

linhas no treino balanceado

- 13 features: 6 numéricas + 6 categóricas + 1 binária.
- Numéricas faltantes por mediana; TP_COTA vazio → “AMPLA”; RobustScaler; One-Hot.
- Divisão estratificada 60/20/20 (treino / validação / teste).
- Undersampling só no treino → 20.330 linhas balanceadas no fit.

Como modelamos

Árvore de Decisão

Random Forest

Gradient Boosting

KNN

Naive Bayes

SVM

- Mesmo pré-processamento para todos -> mesmo processor: input, escala e one-hot
- Tuning em Holdout, otimizando AUC-ROC (robusta ao desbalanceamento) -> Por ser uma base grande, um único Split já traz estimativas estáveis
- Problema do Holdout com GridSearchCV do scikit-learn -> usamos PredefinedSplit para contornar